Dokumentowe bazy danych – MongoDB

Ćwiczenie 2 - zadanie do samodzielnego wykonania

Imię i nazwisko:

Materialy:

Książki

Np.

- Shannon Bradshaw, Eoin Brazil, Kristina Chodorow, MongoDB: The Definitive Guide. Powerful and Scalable Data Storage, O'Reily 2019
- Alex Giamas, Mastering MongoDB 4.x., Pact 2019

Dokumentacja

https://www.mongodb.com/docs/manual/reference/program/mongo/

MongoDB University Courses

- https://university.mongodb.com/courses/catalog
- MongoDB Basics
 - o https://university.mongodb.com/courses/M001/about
- The MongoDB Aggregation Framework
 - o https://university.mongodb.com/courses/M121/about
- Data Modeling
 - o https://university.mongodb.com/courses/M320/about

Yelp Dataset

www.yelp.com - serwis społecznościowy – informacje o miejscach/lokalach

- restauracje, kluby, hotele itd. (businesses),
- użytkownicy piszą recenzje (reviews) o miejscach i wystawiają oceny oceny,
- użytkownicy odwiedzają te miejsca "meldują się" (check-in)
- Przykładowy zbiór danych zawiera dane z 5 miast: Phoenix, Las Vegas, Madison, Waterloo i Edinburgh.

Kolekcje:

```
42,153 businesses
320,002 business attributes
31,617 check-in sets
252,898 users
955,999 edge social graph
403,210 tips
1,125,458 reviews
```

business

```
{
    'type': 'business',
    'business_id': (encrypted business id),
    'name': (business name),
    'neighborhoods': [(hood names)],
    'full_address': (localized address),
    'city': (city),
    'state': (state),
    'latitude': latitude,
    'longitude': longitude,
    'stars': (star rating, rounded to half-stars),
    'review count': review count,
    'categories': [(localized category names)]
    'open': True / False (corresponds to closed, not business hours),
    'hours': {
        (day_of_week): {
            'open': (HH:MM),
            'close': (HH:MM)
        },
    },
    'attributes': {
        (attribute_name): (attribute_value),
   },
}
```

review

```
{
  'type': 'review',
  'business_id': (encrypted business id),
  'user_id': (encrypted user id),
  'stars': (star rating, rounded to half-stars),
  'text': (review text),
  'date': (date, formatted like '2012-03-14'),
  'votes': {(vote type): (count)},
}
```

user

```
{
  'type': 'user',
  'user_id': (encrypted user id),
  'name': (first name),
  'review_count': (review count),
  'average_stars': (floating point average, like 4.31),
  'votes': {(vote type): (count)},
  'friends': [(friend user_ids)],
  'elite': [(years_elite)],
  'yelping_since': (date, formatted like '2012-03'),
  'compliments': {
        (compliment_type): (num_compliments_of_this_type),
        ...
  },
  'fans': (num_fans),
}
```

check-in

```
{
  'type': 'checkin',
  'business_id': (encrypted business id),
  'checkin_info': {
      '0-0': (number of checkins from 00:00 to 01:00 on all Sundays),
      '1-0': (number of checkins from 01:00 to 02:00 on all Sundays),
      ...
      '14-4': (number of checkins from 14:00 to 15:00 on all Thursdays),
      ...
      '23-6': (number of checkins from 23:00 to 00:00 on all Saturdays)
}, # if there was no checkin for a hour-day block it will not be in the dict
}
```

tip

```
{
    'type': 'tip',
    'text': (tip text),
    'business_id': (encrypted business id),
    'user_id': (encrypted user id),
    'date': (date, formatted like '2012-03-14'),
    'likes': (count),
}
```

Zadania

1. Operacje wyszukiwania danych

Dla zbioru Yelp wykonaj następujące zapytania

W niektórych przypadkach może być potrzebne wykorzystanie mechanizmu Aggregation Pipeline https://www.mongodb.com/docs/manual/core/aggregation-pipeline/

a) Zwróć dane wszystkich restauracji (kolekcja businesss, pole *categories* musi zawierać wartość *Restaurants),* które są otwarte w poniedziałki (pole hours) i mają ocenę co najmniej 4 gwiazdki (pole *stars*). Zapytanie powinno zwracać: nazwę firmy, adres, kategorię, godziny otwarcia i gwiazdki. Posortuj wynik wg nazwy firmy.

Standardowe zapytanie spełniające kryteria podpunktu. Metoda find() składa się z 3 parametrów: zapytania, widoku zapytania oraz dodatkowych opcji, gdzie możemy np. posortować wyniki. Poniżej fragment otrzymanych dokumentów.

```
yelp_mongodb_js> db.getCollection('business').find(
             'categories': { $elemMatch: { $eq: 'Restaurants' } },
             'hours.Monday': { $exists: true },
             'stars': { $gte: 4 }
            'name': true,
            'full address': true,
             'categories': true,
             'hours': true,
             'stars': true
        },
            sort: [ 'name' ]
 {
    _id: ObjectId("647e58bf00c163c7414ded87"),
    full_address: '67 Nicolson Street\nNewington\nEdinburgh EH8 9BZ',
    hours: {
      Monday: { close: '22:00', open: '10:00' },
      Tuesday: { close: '22:00', open: '10:00' },
      Friday: { close: '22:00', open: '10:00' },
      Wednesday: { close: '22:00', open: '10:00' }, Thursday: { close: '22:00', open: '10:00' },
      Sunday: { close: '22:00', open: '10:00' },
      Saturday: { close: '22:00', open: '10:00' }
    categories: [ 'Food', 'Desserts', 'Coffee & Tea', 'Indian', 'Restaurants' ],
    name: '10-to-10 In Delhi',
    stars: 4.5
```

b) Ile hoteli znajduje się w każdym mieście. (pole *categories* musi zawierać wartość *Hotels & Travel* lub *Hotels*). Wynik powinien zawierać nazwę miasta, oraz liczbę hoteli. Posortuj wynik malejąco wg liczby hoteli.

W tym zapytaniu korzystam z metody aggregate(), która przyjmuje tablicę obiektów odpowiadających za agregację zapytania. \$match to filtr kategorii hoteli, natomiast \$group, jak sama nazwa wskazuje, to agregator grupy – grupuje każde przedsiębiorstwo po mieście i zlicza liczbę takich hoteli w obrębie każdej grupy, a na koniec sortuje malejąco po tej liczbie malejąco, korzystając z \$sort.

```
yelp_mongodb_js> db.getCollection('business').aggregate(
              { $match: { 'categories': { $in: [ 'Hotels & Travel', 'Hotels' ] } } },
             { $group: { '_id': '$city', 'hotel_count': { $count: {} } } },
             { $sort: { 'hotel_count': -1 } }
         1
...);
  { _id: 'Las Vegas', hotel_count: 485 },
    _id: 'Phoenix', hotel_count: 250 },
    _id: 'Edinburgh', hotel_count: 161 },
    id: 'Scottsdale', hotel_count: 122 },
    _id: 'Madison', hotel_count: 67 },
    _id: 'Tempe', hotel_count: 57 },
    _id: 'Mesa', hotel_count: 53 },
    _id: 'Henderson', hotel_count: 41 },
    _id: 'Chandler', hotel_count: 30 },
    id: 'Glendale', hotel_count: 20 },
    id: 'Peoria', hotel_count: 12 },
    _id: 'North Las Vegas', hotel_count: 12 },
    id: 'Surprise', hotel_count: 10 },
     _id: 'Goodyear', hotel_count: 9 },
_id: 'Middleton', hotel_count: 7 }
     id: 'Casa Grande', hotel_count: 7 },
     _id: 'Gila Bend', hotel_count: 6 },
  { _id: 'Wickenburg', hotel_count: 5 },
{ _id: 'Waterloo', hotel_count: 5 },
{ _id: 'Avondale', hotel_count: 5 }
Type "it" for more
```

c) Ile każda firma otrzymała ocen/wskazówek (kolekcja *tip*) w 2012. Wynik powinien zawierać nazwę firmy oraz liczbę ocen/wskazówek Wynik posortuj według liczby wskazówek (*tip*).

Filtruję za pomocą wyrażenia regularnego wszystkie dokumenty, które mają w dacie 2012 rok (posiadają na początku tekstu 2012). Grupuję i zliczam wszystkie przefiltrowane wskazówki, dołączam kolekcję business do zwróconych wyników, aby wydobyć nazwę firmy (odpowiednik JOIN z relacyjnych baz danych), następnie sortuję malejąco po liczbie sugestii, a na końcu zmieniam widok, żeby zawierał tylko pola: id, nazwę firmy oraz liczbę posiadanych wskazówek. W tym podpunkcie można zauważyć, że kolejność agregacji ma olbrzymie znaczenie na wydajność zapytania, w tym przypadku złe ułożenie przyczyniało się do wydłużenia czasu obliczania zapytania do ponad 15 minut, np. \$sort po \$project z \$lookup.

```
{ $group: {
    '_id': '$business_id',
            'tip_count': { $count: {} }
         } },
{
            $lookup: {
    from: 'business',
                 localField: '_id',
                foreignField: 'business_id',
                as: 'business'
        },
{ $sort: { 'tip_count': -1 } },
         { $project: { 'business_name': { $first: '$business.name' }, 'tip_count': 1 } }
...]);
     _id: 'jf67Z1pnwElRSXllpQHiJg',
    tip_count: 1084,
    business_name: 'McCarran International Airport'
  },
     _id: 'hW0Ne_HTHEAgGF1rAdmR-g',
    tip_count: 622,
business_name: 'Phoenix Sky Harbor International Airport'
    _id: '2e2e7WgqU1BnpxmQL5jbfw',
tip_count: 430,
business_name: 'Earl of Sandwich'
  },
    _id: 'CsNOg-u_wCuXSt9Z-xU92Q',
    tip_count: 374,
business_name: 'Las Vegas Athletic Club Southwest'
```

d) Recenzje mogą być oceniane przez innych użytkowników jako *cool, funny* lub *useful* (kolekcja review, pole votes, jedna recenzja może mieć kilka głosów w każdej kategorii). Napisz zapytanie, które zwraca dla każdej z tych kategorii, ile sumarycznie recenzji zostało oznaczonych przez te kategorie (np. recenzja ma kategorię *funny* jeśli co najmniej jedna osoba zagłosowała w ten sposób na daną recenzję)

Zamieniam obiekt votes na tablicę klucz-wartość, następnie rozpakowywuję tablicę za pomocą \$unwind, pozbywam się wszystkich dokumentów z liczbą ocen z danej kategorii równą 0. count to liczba wszystkich niezerowych ocen, natomiast total sumuje liczbę wszystkich ocen, tj. jeśli w jednym dokumencie v będzie miało wartość 2, a w drugim 3 (k będzie równe) to count zwróci 2, a total 5.

e) Zwróć dane wszystkich użytkowników (kolekcja *user*), którzy nie mają ani jednego pozytywnego głosu (pole *votes*) z kategorii (*funny lub useful*), wynik posortuj alfabetycznie według nazwy użytkownika.

```
yelp mongodb_js> db.getCollection('user').aggregate([
            $match: {
                'votes.funny': 0,
                'votes.useful': 0,
                'type': 'user'
        { $sort: { 'name': 1 } }
...]);
[
    _id: ObjectId("647e5b9300c163c7415b8bdd"),
    yelping_since: '2009-08',
    votes: { funny: 0, useful: 0, cool: 0 },
    review_count: 1,
    name: 'Bernard',
    user_id: 'xP3SPgfgW2vc5Zj5uV8SEA',
    friends: [],
    fans: 0,
    average_stars: 5,
    type: 'user',
    compliments: {},
    elite: []
     id: ObjectId("647e5bc600c163c7415df5f3"),
    yelping_since: '2013-03',
    votes: { funny: 0, useful: 0, cool: 0 },
    review_count: 1,
    name: ',Maria',
    user_id: 'Os5f3TNpM7_A8IDNEdPX2g',
    friends: [],
    fans: 0,
    average_stars: 5,
    type: 'user',
    compliments: {},
    elite: []
```

f) Wyznacz, jaką średnia ocenę uzyskała każda firma na podstawie wszystkich recenzji (kolekcja *review*, pole *stars*). Ogranicz do firm, które uzyskały średnią powyżej 3 gwiazdek.

przypadek 1: Wynik powinien zawierać id firmy oraz średnią ocenę. Posortuj wynik wg id firmy.

Na początku grupuję po polu business_id, agregując dodatkowo średnią opinii, wyświetlam tylko te opinie, które posiadają średnią większą niż 3, a na koniec sortuję wyniki po id firmy (_id).

```
yelp mongodb js> db.getCollection('review').aggregate([
         $group: {
             _id': '$business_id',
             'stars mean': { $avg: '$stars' }
         }
      { $match: { 'stars_mean': { $gt: 3 } } },
      { $sort: { '_id': 1 } }
...]);
   id: '-0HGqwlfw3I8nkJyMHxAsQ', stars_mean: 4 },
   _id: '-1bOb2izeJBZjHC7NWxiPA', stars_mean: 3.824324324324324324 },
   id: '-34jE 5dujSWMIOBudQsiQ', stars mean: 4.75 },
   _id: '-3JXOT-i2gDbASLgDeOSwQ', stars_mean: 4.75 },
   _id: '-3WVw1TNQbPBzaKCaQQ1AQ', stars_mean: 3.7892156862745097 },
  _id: '-3qWPkQAxsggQJYqgi5myA', stars_mean: 3.25 },
   _id: '-3xbryp44xhpN4BohxXDdQ', stars_mean: 3.8151260504201683 },
   _id: '-4BtfPW3_v092G8pqHrv4w', stars_mean: 3.625 },
  _id: '-4zMr3jk0ykmsk5sxsQMlA', stars_mean: 4 },
   _id: '-5IgAihccTd8_iENVgpd9A', stars_mean: 3.5 },
   _id: '-5bLhMLNGbIVyoPOV10yLg', stars_mean: 3.33333333333333333333}},
   _id: '-63VfA2tnYyzwRt81B1AKw', stars_mean: 4.0588235294117645 },
   _id: '-65rmLRQ5JDwI-18UDEV7Q', stars_mean: 3.8 },
   _id: '-6Ft3hulif702sIdKiG00g', stars_mean: 4.5 },
   id: '-6053B-ksqSKzWM6Y9moEQ', stars_mean: 3.25 },
   _id: '-6Roo-EHgSdUa4rP3tWyRw', stars_mean: 3.4571428571428573 },
```

przypadek 2: Wynik powinien zawierać nazwę firmy oraz średnią ocenę. Posortuj wynik wg nazwy firmy.

Do zapytania z przypadku 1 dodałem relację z kolekcją business, wyłuskując tylko nazwę firmy za pomocą pipeline. Czas oczekiwania na zapytanie jest bardzo długi z powodu natury zapytania i struktury bazy Yelp, mianowicie sortowanie i pozyskiwanie danych spoza bazowej kolekcji za pomocą \$lookup zdecydowanie zmniejsza wydajność.

```
db.getCollection('review').aggregate([
        $group: {
            '_id': '$business_id',
            'stars_mean': { $avg: '$stars' }
    { $match: { 'stars_mean': { $gt: 3 } } },
        $lookup: {
            from: 'business',
            localField: '_id',
            foreignField: 'business_id',
            pipeline: [{ $group: { '_id': '$name' } }],
            as: 'business'
        $project: {
            '_id': 0,
            'business_name': { $first: '$business._id' },
            'stars_mean': 1
    { $sort: { 'business_name': 1 } }
```

```
yelp_mongodb_js> db.getCollection('review').aggregate([
           $group: {
               '_id': '$business id',
               'stars_mean': { $avg: '$stars' }
...
         $match: { 'stars_mean': { $gt: 3 } } },
. . .
           $lookup: {
               from: 'business',
               localField: 'id',
               foreignField: 'business id',
. . .
               pipeline: [{ $group: { '_id': '$name' } }],
               as: 'business'
...
           }
       },
...
           $project: {
               '_id': 0,
               'business_name': { $first: '$business._id' },
               'stars_mean': 1
...
       },
. . .
       { $sort: { 'business_name': 1 } }
...]);
 { stars_mean: 4.125, business_name: '#1 Brothers Pizza' },
  { stars_mean: 4.0555555555555555, business_name: '19th Donut Hole' },
  { stars mean: 4.375, business name: '1st Emergency Pet Care' },
  { stars_mean: 4.928571428571429, business_name: '1st Nails II' },
   stars_mean: 3.944444444444446,
   business_name: '1st Pet Veterinary Centers'
 },
   stars_mean: 3.0714285714285716,
   business_name: '2 Men and A Pizza'
 },
  { stars_mean: 3.5, business_name: '2007 Nails' },
   stars_mean: 3.5454545454545454, business_name: '24 Hour Fitness'
```

W sprawozdaniu należy umieścić zrzuty ekranów (z kodem poleceń oraz z uzyskanymi wynikami). Dodatkowo należy dołączyć plik tekstowy (najlepiej z rozszerzeniem .js) zawierający kod poleceń

2. Modelowanie danych

- Zaproponuj strukturę bazy danych dla wybranego/przykładowego zagadnienia/problemu
- Należy wybrać jedno zagadnienie/problem (A lub B)

Przykład A

- Wykładowcy, przedmioty, studenci, oceny
- Wykładowcy prowadzą zajęcia z poszczególnych przedmiotów
- Studenci uczęszczają na zajęcia
- Wykładowcy wystawiają oceny studentom
- Studenci oceniają zajęcia

Przykład B

- Firmy, wycieczki, osoby
- Firmy organizują wycieczki
- Osoby rezerwują miejsca/wykupują bilety
- Osoby oceniają wycieczki

Wybieram model A - baza danych uczelni.

a) Warto zaproponować/rozważyć różne warianty struktury bazy danych i dokumentów w poszczególnych kolekcjach oraz przeprowadzić dyskusję każdego wariantu (wskazać wady i zalety każdego z wariantów)

Wariant 1

Struktura bazy danych jest podzielona na 3 kolekcje: wykładowców, przedmioty i studentów. W tym modelu położyłem nacisk na redundancję danych i spójność, stosując podobny do relacyjnych baz danych model.

Zalety:

- · Redundancja danych;
- Spójność;
- Duża wydajność dla poszczególnych kolekcji;
- Niewielki rozmiar dokumentów.

Wady:

- Średnia lub mała wydajność dla poszczególnych kolekcji przy zapytaniach agregacyjnych, które łączą kilka kolekcji;
- Zamodelowanie typowych dla tej bazy danych zapytań wymaga już łączenia kilku kolekcji;
- Mała czytelność z powodu posiadanych licznych obiektów ObjectId.

```
// Lecturers
const exampleLecturer1 = {
    "personalDetails": {
        "firstName": "John",
        "lastName": "Doe",
        "realLifeId": "532214321",
        "nationality": "Scottish"
        // pozostate dane, nr telefonu, email uczelniany itd.
        // ...
    },
    "faculty": "Faculty of Computer Science, Electronics and
Telecomunications",
    "degree": "Doctor of Philosophy",
    "roles": [
        "Head of the department"
        // ...
    ],
    "taughtCourses": [
        ObjectId("_id_course_0"),
        ObjectId("_id_course_1")
        // ...
    ]
};
```

```
const exampleStudent1 = {
    "personalDetails": {
        "firstName": "Anne",
        "lastName": "Kowalski",
        "realLifeId": "00211388482",
       "nationality": "Polish"
    "major": "Computer Science",
    "faculty": "Faculty of Computer Science, Electronics and
Telecomunications",
    "participatedCourses": [
       ObjectId("_id_course_0"),
        ObjectId("_id_course_1"),
       ObjectId("_id_course_2")
    "grades": [
            "value": 4.5,
            "date": new Date(),
            "issuedBy": ObjectId("_id_john_doe"),
            "courseId": ObjectId("_id_dsa_course")
```

Wariant 2

Struktura bazy danych jest podzielona także na 3 kolekcje: wykładowców, przedmioty i studentów. W tym modelu położyłem nacisk na wydajność modelu, stosując zagnieżdżone dokumenty, które zawierają pełne informacje.

Zalety:

- Duża wydajność zapytań bez względu na ich rodzaj;
- Posiadanie wszystkich danych w jednej kolekcji bez potrzebnej agregacji;

Wadv:

- Bardzo duża powtarzalność tych samych danych poprzez powielenie dokumentów;
- Bardzo duży rozmiar dokumentów jak i samej bazy;

- Integralność między danymi jest utrudniona, w wypadku modyfikacji pojedynczego dokumentu w kolekcji należy zmodyfikować inne, gdzie występuje ten sam dokument także.
- Mała czytelność przez ilość danych w pojedynczym dokumencie.

Wariant 3

Wariant ten to wariant 2 z redukowaną liczbą pól, tablice obiektów w postaci grades, reviews, itd. zostały usunięte.

Zalety:

- Duża wydajność zapytań większości standardowych zapytań;
- Posiadanie wszystkich kluczowych danych w jednej kolekcji bez potrzebnej agregacji;
- Czytelność.

Wady:

- Duża powtarzalność tych samych danych poprzez powielenie dokumentów;
- Duży rozmiar dokumentów jak i samej bazy;
- Integralność między danymi jest utrudniona, w wypadku modyfikacji pojedynczego dokumentu w kolekcji należy zmodyfikować inne, gdzie występuje ten sam dokument także.
- Czasami trzeba zastosować agregację danych, łącząc kilka kolekcji, by pozyskać odpowiednie informacje.

Wariant 4

Struktura bazy danych danych z poprzednich punktów zostaje zmieniona, powstają 2 nowe kolekcje w postaci ocen i opinii. W tym modelu można zastosować łączenie relacji poprzez ich identyfikatory lub częściowe zagnieżdżanie dokumentów tak jak w wariancie 3.

b) Kolekcje należy wypełnić przykładowymi danymi

Zrobiłem to w punkcie a.

 c) W kontekście zaprezentowania wad/zalet należy zaprezentować kilka przykładów/zapytań/zadań/operacji oraz dla których dedykowany jest dany wariantów

W sprawozdaniu należy zamieścić przykładowe dokumenty w formacie JSON (pkt a) i b)), oraz kod zapytań/operacji (pkt c)), wraz z odpowiednim komentarzem opisującym strukturę dokumentów oraz polecenia ilustrujące wykonanie przykładowych operacji na danych

Do sprawozdania należy kompletny zrzut wykonanych/przygotowanych baz danych (taki zrzut można wykonać np. za pomocą poleceń mongoexport, mongdump ...) oraz plik z kodem operacji zapytań (załącznik powinien mieć format zip).

Punktacja za zadanie (razem 2pkt)